编译原理复习

Garone Lombard

2023 年 12 月 7 日

摘要

编译原理烤漆复习手册

目录

1 文法和语言

文法定义 四元组

$$G = (V_T, V_N, P, S) \tag{1}$$

1.1 文法的分类

0 型文法 无限制文法，只要求产生式的左部存在一个非终结符即可。

$$\forall \alpha \to \beta \in P \qquad \alpha\text{中至少包含一个}V_N \tag{2}$$

1 型文法 上下文有关文法，在0 型文法的基础上 进一步要求产生式的左部长度小于等于右部长度

$$\begin{gathered} \forall \alpha \to \beta \in P \qquad |\alpha| \leq |\beta| \\ \text{产生式的一般形式} \quad \alpha 1 A \alpha 2 \to \alpha 1 \beta \alpha 2 (\beta \neq \epsilon) \end{gathered} \tag{3}$$

2 型文法 上下文无关文法 (**可以描述大部分程序设计语言的文法构造**)，要求产生式的左部只能是一个非终结符

$$\forall \alpha \to \beta \in P \qquad \alpha \in V_N \tag{4}$$

3 型文法 正则文法，只有两种形式，左线性文法 or 右线性文法 (注意是要求某一文法的所有产生式均符合左/右线性文法，而不只是 P1 满足左线性，P2 满足右线性)。
正则文法和正则表达式是等价的，对于任意一个正则文法 G，都存在定义同一语言的正则表达式 r，反之亦然。

- 左线性文法：$A \to \omega B \quad or \quad A \to \omega$
- 右线性文法：$A \to B\omega \quad or \quad A \to \omega$

例如

$$
\begin{aligned}
&S \rightarrow a|b|c|d \\
&S \rightarrow aT|bT|cT|dT \\
&T \rightarrow a|b|c|d|0|1|2|3|4|5 \\
&T \rightarrow aT|bT|cT|dT|0T|1T|2T|3T|4T|5T
\end{aligned}
$$

1.2 (句型的) 短语

已知文法

$$
\begin{aligned}
&E \rightarrow E+E \\
&E \rightarrow E*E \\
&E \rightarrow -E \\
&E \rightarrow (E) \\
&E \rightarrow idenfr
\end{aligned}
$$

对于句型：$-(E+E)$，可构造如下分析树

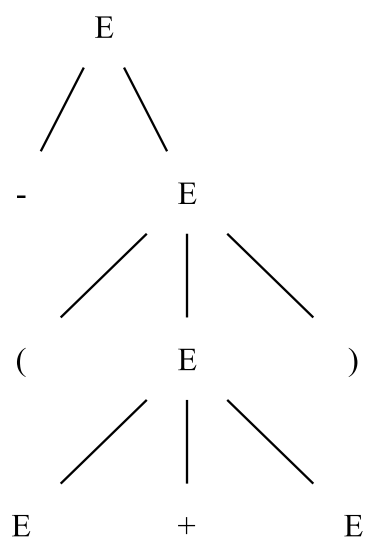

图 1: 分析树

- $E+E$ 是句型 $-(E+E)$ 相对于规则 $E \to E+E$ 的短语, 直接短语, 句柄 (子树层级为 1)
- $(E+E)$ 是句型 $-(E+E)$ 相对于规则 $E \to (E)$ 的短语
- $-(E+E)$ 是句型 $-(E+E)$ 相对于规则 $E \to -E$ 的短语

需要注意的是，直接短语一定是某产生式的右部，但某产生式的右部不一定是给定句型的直接短语

2　词法分析

2.1　有穷自动机

基本概念　省略...

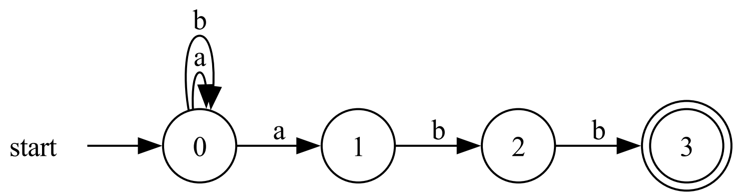

图 2: FA

最长前缀匹配原则 当输入串的多个前缀与一个或多个模式匹配时，总是选择最长的前缀匹配。也就是说在到达某个终态后，只要输入串上还有符号，FA 就会继续读入下一个符号，以寻求尽可能长度的匹配。

正则表达式和有穷自动机是等价的

2.1.1 确定的有穷自动机 (DFA)

定义 DFA 是一个五元组，$M = (S, \Sigma, \delta, s_0, F)$

- S：有穷状态集
- Σ：输入符号表
- δ：状态转移函数，$\forall s \in S, a \in \Sigma, \delta(s, a)$ 表示从状态 s 出发，沿着标记为 a 的边所能到达的状态 (唯一)
- s_0：初始状态
- F：终态集

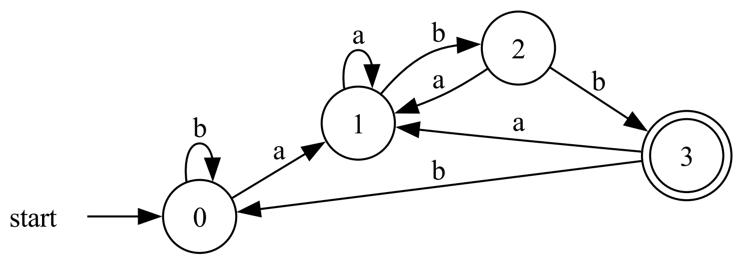

图 3: DFA

状态 \ 输入	a	b
0	1	0
1	1	2
2	1	3
3*	1	0

表 1: 转换表

DFA 的算法实现

- 输入：以文件结束符 eof 结尾的字符串 x，DFA M 的开始状态 s_0，接受状态集合 F，状态转换函数 $move(s, a)$
- 输出：M 接受则输出"yes"，拒绝则输出"no"
- 算法：

```
s=s0;
c=nextChar();
while(c!=eof){
    s=move(s,c);
    c=nextChar();
}
if(s in F) output("yes");
```

```
else output("no");
```

2.1.2 不确定的有穷自动机 (NFA)

定义 NFA 是一个五元组，$M = (S, \Sigma, \delta, s_0, F)$

- S：有穷状态集
- Σ：输入符号表
- δ：状态转移函数，$\forall s \in S, a \in \Sigma, \delta(s, a)$ 表示从状态 s 出发，沿着标记为 a 的边所能到达的状态**集合**
- s_0：初始状态
- F：终态**集**

NFA 和 DFA 的唯一区别就是状态转换函数的状态不唯一

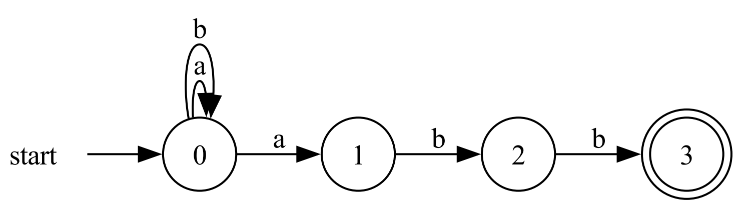

图 4: NFA

状态 \ 输入	a	b
0	{0,1}	{0}
1	ϕ	{2}
2	ϕ	{3}
3*	ϕ	ϕ

表 2: 转换表

DFA 和 NFA 具有等价性，即对于任意一个 NFA，都存在一个 DFA，使得两者能够识别相同的语言，反之亦然。

带有 ϵ 转换的 NFA ϵ-NFA，是一种特殊的 NFA，其状态转换函数 δ 中，$\delta(s, \epsilon)$ 表示从状态 s 出发，不读入任何输入符号，直接转移到下一个状态。

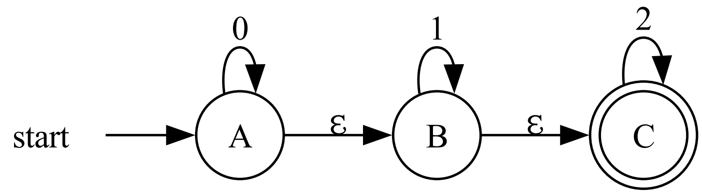

图 5: ϵ-NFA

可以证明，对于任意一个 ϵ-NFA，都存在一个 DFA，使得两者能够识别相同的语言，反之亦然。

也就是说，*DFA*、*NFA*、*ϵ-NFA 都具有等价性*。

2.1.3 从正则表达式到 DFA 的转换

直接将正则表达式转换为 DFA 相当困难，所以一般采取 $RE->NFA->DFA$ 的形式

正则表达式到 NFA 的转换 对应关系如下

- ϵ 对应的 NFA

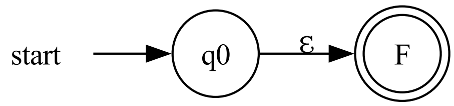

- 字母表 Σ 中符号 a 对应的 NFA

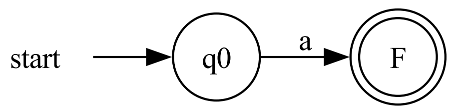

- $r = r_1 r_2$ 对应的 NFA

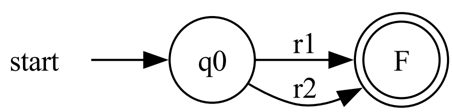

- $r = (r_1)*$ 对应的 NFA

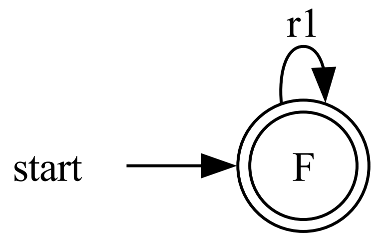

- $r = (a|b)^*abb$ 对应的 NFA

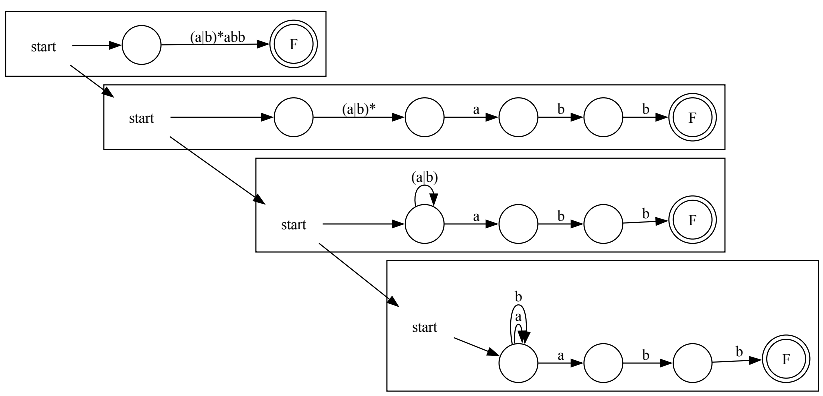

NFA 到 DFA 的转换 如下所示

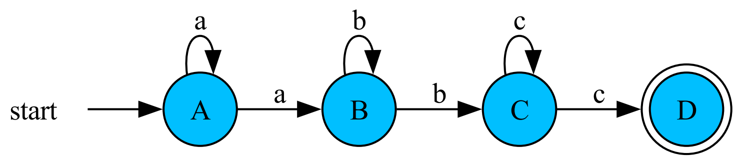

首先绘制状态转换表

输入 / 状态	a	b	c
A	{A,B}	ϕ	ϕ
B	ϕ	{B,C}	ϕ
C	ϕ	ϕ	{C,D}
D*	ϕ	ϕ	ϕ

表 3: 转换表

与 NFA 等价的 DFA 的每一个状态都是一个由 NFA 状态构成的集合

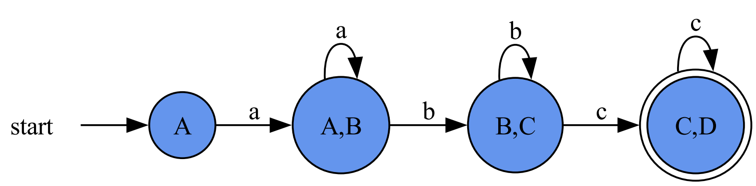

ϵ-NFA 到 DFA 的转换

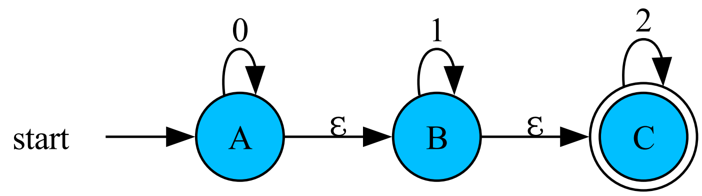

同样绘制状态转换表

输入 / 状态	0	1	2
A	{A,B,C}	{B,C}	{C}
B	ϕ	{B,C}	{C}
C*	ϕ	ϕ	{C}

表 4: 转换表

需要注意的是，由于初始即可达 A,B,C，所以初始状态应该是 A,B,C 而不是 A

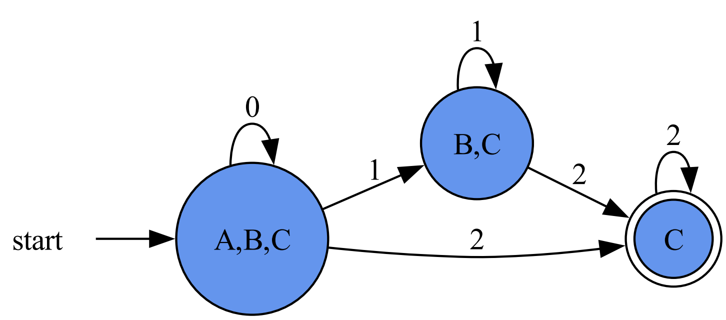

子集构造法

- 输入：NFA N
- 输出：DFA D
- 算法：一开始，$\epsilon - closure(s_0)$ 是 Dstates 中唯一的状态，且未加标记;

```
while(在Dstates中有一个未标记状态T){
    tag(T);
    for(每个输入符号a){
        U=closure(move(T,a));
        if(U not in Dstates){
            add(Dstates,U);
        }
        Dtran[T,a]=U;
    }
}
```

操作	描述
$\epsilon - closure(s)$	能够从 NFA 的开始状态只通过 ϵ 转换直接到达的 NFA 状态集合
$\epsilon - closure(T)$	能从集合 T 中的某个 NFA 状态只通过 ϵ 转换直接到达的 NFA 状态集合
$move(T, a)$	能从集合 T 中的某个 NFA 状态通过标号为 a 的转换到达的 NFA 状态的集合

NFA 的化简例题 ◦◦◦◦◦◦

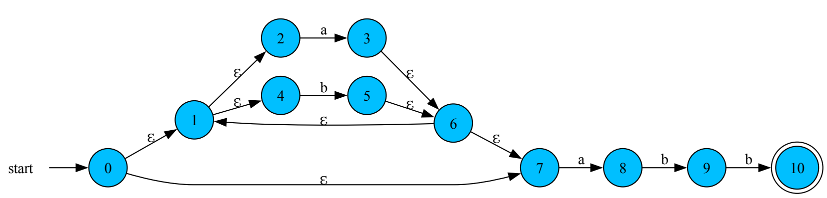

图 6: NFA

输入 状态	a	b
0	{1,2,3,4,6,7,8}	{1,2,4,5,6,7}
1	{1,2,3,4,6,7}	{1,2,4,5,6,7}
2	{1,2,3,4,6,7}	ϕ
3	{1,2,3,4,6,7,8}	{1,2,4,5,6,7}
4	ϕ	{1,2,4,5,6,7}
5	{1,2,3,4,6,7,8}	{1,2,4,5,6,7}
6	{1,2,3,4,6,7,8}	{1,2,4,5,6,7}
7	{8}	ϕ
8	ϕ	{9}
9	ϕ	{10}
10*	ϕ	ϕ

表 5: 转换表 1(无效)

$\epsilon - closure(T_0)$	{0,1,2,4,7}	
输入 状态	a	b
T0={0,1,2,4,7}	{1,2,3,4,6,7,8}	{1,2,4,5,6,7}
T1={1,2,3,4,6,7,8}	{1,2,3,4,6,7,8}	{1,2,4,5,6,7,9}
T2={1,2,4,5,6,7}	{1,2,3,4,6,7,8}	{1,2,4,5,6,7}
T3={1,2,4,5,6,7,9}	{1,2,3,4,6,7,8}	{1,2,4,5,6,7,10}
T4={1,2,4,5,6,7,10}	{1,2,3,4,6,7,8}	{1,2,4,5,6,7}

表 6: 转换表 2(正确)

状态 \ 输入	a	b
T0={0,1,2,4,7}	T1	T2
T1={1,2,3,4,6,7,8}	T1	T3
T2={1,2,4,5,6,7}	T1	T2
T3={1,2,4,5,6,7,9}	T1	T4
T4*={1,2,4,5,6,7,10}	T1	T2

表 7: 转换表 2(正确)

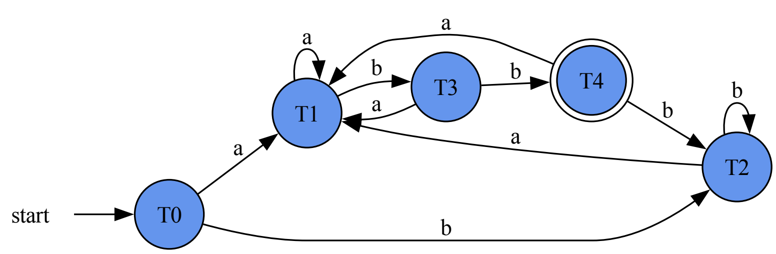

图 7: DFA

2.1.4 DFA 的最小化

概念 一个有穷自动机可以通过消除无用状态和合并等价状态来最小化

- 无用状态：从该自动机的开始状态出发，任何输入串都无法到达的状态 (从该状态出发，没有通路抵达终态)
- 等价状态：条件如下
  1. 一致性条件：状态 s 和 t 必须同时为可接受状态或不可接受状态
  2. 蔓延性条件：对于所有输入符号，状态 s 和 t 必须转换到等价态

分割法 把一个 DFA(不含无用态) 的状态分成一些不相交的子集，使得任何不同的两个子集的状态都是可区分的，且同一个子集中的任何状态都是等价的

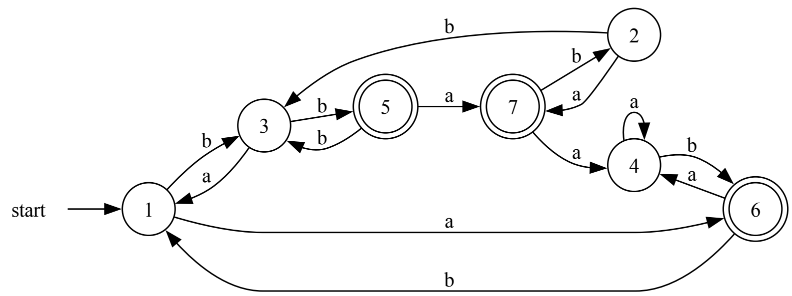

第一步都是固定的，把状态分为终态和非终态两个集合 {1,2,3,4},{5,6,7}
接下来考察 {1,2,3,4} 是否可分

状态＼输入	a	b
1	6(E)	3(NE)
2	7(E)	3(NE)
3	1(NE)	5(E)
4	4(NE)	6(E)

因此可以将集合拆分为 {1,2},{3,4},{5,6,7}

状态＼输入	a	b
1	6(P3)	3(P2)
2	7(P3)	3(P2)

显然 {1,2} 不可拆分

状态＼输入	a	b
3	1(P1)	5(P3)
4	4(P2)	6(P3)

{3,4} 可拆分为 {3},{4}
此时集合为 {1,2},{3},{4},{5,6,7}

状态 \ 输入	a	b
5	7(P4)	3(P2)
6	4(P3)	1(P1)
7	4(P3)	2(P1)

{5,6,7} 可拆分为 {5},{6,7}
因此最终得到的集合为 {1,2},{3},{4},{5},{6,7}

状态 \ 输入	a	b
1	6(P5)	3(P2)
2	7(P5)	3(P2)
3	1(P1)	5(P4)
4	4(P3)	6(P5)
5	7(P5)	3(P2)
6	4(P3)	1(P1)
7	4(P3)	2(P1)

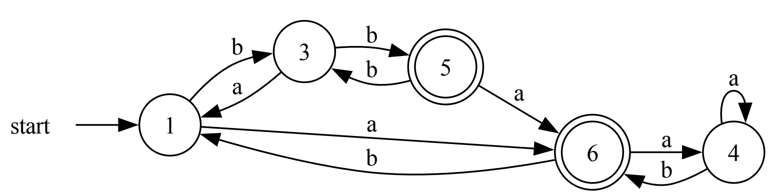

图 8: 最小化后的 DFA

3 语法分析

3.1 自顶向下语法分析

概念 从分析树的顶部向底部方向构造分析树，也就是从文法开始符号 S 从左向右推导句子 w 的过程

最左推导 总是选择每个句型的最左非终结符进行替换，其反过程称为最右规约

最右推导 总是选择每个句型的最右非终结符进行替换，其反过程称为最左规约

在自底向上的分析中，总是采用最左规约的方式，因此**把最左规约成为规范规约**，而**把最右推导称为规范推导**

最左推导和最右推导具备唯一性，因为对于每个句型而言，其最左/右终结符是唯一的

3.2 文法转换

左递归文法 如果一个文法中有一个非终结符 A 使得对某个串存在推导 $A \rightarrow^{+} Aa$，那么这个文法就是左递归文法，这会使递归下降分析器陷入无限循环

处理办法如下 (可消除直接左递归, 其实是将其转化为了右递归)

$$\begin{aligned} A &\rightarrow A\alpha|\beta \\ A &\rightarrow A\alpha \rightarrow A\alpha\alpha\alpha\alpha \rightarrow \beta\alpha\alpha\alpha\alpha \ldots \\ regex &= \beta\alpha^{*} \\ A &\rightarrow \beta A^{'} \\ A^{'} &\rightarrow \alpha A^{'}|\epsilon \end{aligned} \tag{5}$$

同理，对于左递归推导 $E \rightarrow E + T|T$，消除左递归可得一下等价文法

$$\begin{aligned} E &\rightarrow TE^{'} \\ E^{'} &\rightarrow +TE^{'}|\epsilon \end{aligned} \tag{6}$$

ϵ 产生式的使用时机 如果当前某终结符 A 与当前输入 a 不匹配时，若存在 $A \to \epsilon$，可以通过检查 a 是否可以出现在 A 的后面 (那不就是查看 A 的 FOLLOW 集吗?)，来决定是否可以使用产生式 $A \to \epsilon$

3.2.1 FIRST 集

概念 串首终结符，给定一个文法符号串 a，a 的 FIRST(a) 被定义为可以从 a 推导出的所有串首终结符的集合

3.2.2 FOLLOW 集

概念 可能在某个句型中紧跟在 A 后边的终结符 a 的集合

如果 A 是某个句型的最右符号，则将结束符 # 添加到 FOLLOW(A) 中

3.2.3 SELECT 集

概念 产生式 $A \to \beta$ 的可选集是指可以选用该产生式进行推导时对应的输入符号的集合，记为 $SELECT(A \to \beta)$

- $SELECT(A \to \alpha\beta) = \{\alpha\}$
- $SELECT(A \to \epsilon) = FOLLOW(A)$

如果每个具有*相同左部*的各个产生式的可选集互不相交的话，就可以做出确定的分析

3.3 自底向上语法分析